

รายงานสรุปโปรเจกต์

High-Throughput Image Classification Service: The MLOps Challenge

ระบบ API จำแนกรูปภาพด้วย FastAPI และโมเดล apple/mobilevit-small

สมาชิกกลุ่ม

- นายธนัสถ์ภณ อ่างทอง รหัสนักศึกษา 1650901034
- นายจีฮาน สุทธินิพนธ์นาม รหัสนักศึกษา 1650904152
- นายอภินันท์ เกษเพชร รหัสนักศึกษา 1650904269

บทนำ

โปรเจกต์นี้จัดทำขึ้นเพื่อพัฒนา API สำหรับจำแนกรูปภาพที่สามารถนำไปใช้งานได้จริง โดยให้ความสำคัญกับการปรับแต่งโมเดล การจัดการ request พร้อมกัน การบรรจุระบบด้วย Docker และการเตรียมกระบวนการ CI/CD สำหรับการส่งมอบระบบ

1. รายละเอียดโมเดลที่เลือกและจุดประสงค์การใช้งาน

โมเดลที่เลือกใช้คือ apple/mobilevit-small จาก Hugging Face ซึ่งเป็นโมเดลสำหรับงาน Image Classification ที่มีขนาดเล็กและเหมาะกับงาน inference บน CPU โมเดลนี้ผสมแนวคิดของ CNN และ Transformer ทำให้สามารถเรียนรู้ทั้งรายละเอียดเฉพาะจุดและภาพรวมของรูปภาพได้ดี

- จุดประสงค์หลักของระบบคือรับไฟล์รูปภาพจากผู้ใช้และส่งผลการจำแนกกลับในรูปแบบ JSON
- ระบบใช้ ONNX Quantized เป็น runtime หลัก เพื่อลดขนาดโมเดลและลดภาระการประมวลผล
- ผลการทำนายประกอบด้วยชื่อ class และค่าความมั่นใจของแต่ละผลลัพธ์

2. ผลการ Optimization

กระบวนการ optimization ประกอบด้วยการแปลงโมเดลจาก PyTorch เป็น ONNX และการทำ Dynamic Quantization กับ layer ประเภท MatMul และ Gemm เพื่อให้โมเดลมีขนาดเล็กลงและยังสามารถทำงานบน ONNX Runtime CPU ได้จริง

รูปแบบโมเดล	ขนาดโมเดล (MB)	Latency เฉลี่ย (ms)	Latency P95 (ms)
PyTorch	21.44	34.43	37.51
ONNX	21.49	55.58	63.64
ONNX Quantized	11.56	47.00	56.47

จากผลการทดสอบพบว่า ONNX Quantized ลดขนาดโมเดลจาก 21.49 MB เหลือ 11.56 MB คิดเป็นการลดขนาดประมาณ 46% และมี latency ต่ำกว่า ONNX ปกติบนเครื่องที่ใช้ทดสอบ

3. กลยุทธ์การจัดการ Error Handling และ Data Validation

ระบบตรวจสอบข้อมูลก่อนเข้าสู่ขั้นตอน inference เพื่อป้องกันไฟล์ที่ไม่ถูกต้องและลดโอกาสเกิด error ระหว่างประมวลผล โดยมีการตอบกลับ HTTP status code ที่เหมาะสมกับแต่ละกรณี

กรณี	แนวทางจัดการ	ผลลัพธ์
ชนิดไฟล์ไม่ถูกต้อง	อนุญาตเฉพาะ JPEG, PNG และ WebP	400 Bad Request
ไฟล์ว่างหรือไฟล์เสีย	ตรวจสอบข้อมูลไฟล์และความสมบูรณ์ของรูปภาพ	400 Bad Request
ไฟล์ใหญ่เกินกำหนด	จำกัดขนาดไฟล์สูงสุด 5 MB	413 Request Entity Too Large
เกิดข้อผิดพลาดระหว่าง inference	ดักจับ error และส่งข้อความอธิบายกลับ	500 Internal Server Error

4. ผลการทดสอบจาก JMeter และบทวิเคราะห์ประสิทธิภาพ

การทดสอบโหลดใช้การส่ง request พร้อมไฟล์รูปภาพไปยัง endpoint /predict เพื่อประเมินความสามารถของระบบเมื่อมีผู้ใช้งานพร้อมกันหลายรายการ

หัวข้อ	ผลการทดสอบ
Runtime ของโมเดล	onnx-quantized
จำนวน request	30
จำนวน concurrent users	10
จำนวน request ที่สำเร็จ	30/30
Throughput	10.32 requests/second
Average Latency	874.90 ms
P95 Latency	1187.96 ms

ผลการทดสอบแสดงให้เห็นว่าระบบสามารถตอบสนอง request ได้ครบทุกครั้งในชุดทดสอบขนาดเล็ก โดยค่า P95 latency อยู่ที่ประมาณ 1.19 วินาที เมื่อเพิ่มจำนวนผู้ใช้งานพร้อมกันมากขึ้น ระบบจะเริ่มใช้ทรัพยากร CPU มากขึ้น ซึ่งเป็นลักษณะปกติของงาน inference

5. แผนผังระบบและภาพรวม CI/CD Pipeline

ภาพรวมระบบประกอบด้วย Client สำหรับส่งรูปภาพ, FastAPI สำหรับรับ request และตรวจสอบข้อมูล, ProcessPoolExecutor สำหรับแยกงาน inference, ONNX Quantized Model สำหรับทำนายผล, Docker สำหรับบรรจุระบบ และ GitHub Actions สำหรับทดสอบอัตโนมัติ

ส่วนประกอบ	หน้าที่
Client	ส่งไฟล์รูปภาพมายัง API
FastAPI	รับ request ตรวจสอบข้อมูล และส่ง response
ProcessPoolExecutor	แยกงาน inference ที่ใช้ CPU ออกจาก event loop
ONNX Quantized Model	ประมวลผลและทำนาย class ของรูปภาพ
Docker	บรรจุแอปพลิเคชันและโมเดลให้นำไปรันได้ง่าย

ส่วนประกอบ	หน้าที่
GitHub Actions	รัน unit test และเตรียม deploy ไปยัง Cloud

ในส่วน CI/CD เมื่อมีการ push โค้ดไปยัง branch main ระบบจะรัน unit test โดยอัตโนมัติ หากการทดสอบผ่านทั้งหมดจึงสามารถนำไปต่อยอดสู่การ deploy บน Hugging Face Spaces ได้

6. สรุปผล

จากการดำเนินงานสามารถพัฒนา API จำแนกรูปภาพด้วยโมเดล apple/mobilevit-small ได้สำเร็จ ระบบสามารถรันผ่าน Docker รับไฟล์รูปภาพจริง และตอบกลับผลการทำนายด้วย ONNX Quantized Runtime ได้ พร้อมทั้งมีการเตรียมเอกสาร README, workflow สำหรับ CI/CD, Postman Collection และ JMeter Test Plan ซึ่งสอดคล้องกับข้อกำหนดของโปรเจกต์